

Dokumentacja Specyfikacji Wymagań (SRS)

Projekt: Pełna Analiza sentymentu piosenek z list Billboard (przetwarzanie tekstu i analiza sentymentu z wykorzystaniem słowników w plikach CSV)

Wersja dokumentu: 1.0

Data: 07.06.2026

Autor: [Jakub Frommholz, Magdalena Rychlewska]

1. Wprowadzenie:

Niniejszy dokument opisuje specyfikację wymagań dla skryptu R, który analizuje teksty piosenek znajdujących się na "Billboard Year-End Hot 100 singles". Projekt obejmuje analizę tekstów dla wybranych lat: 2000, 2005, 2010, 2015, 2020 i 2025. Dla każdego z tych lat wybrano teksty dziesięciu najwyżej sklasyfikowanych piosenek.

System umożliwia wczytanie tekstów piosenek zapisanych w plikach .txt, pobranie i odczytanie metadanych (takich jak tytuł, wykonawca, rok, miejsce na liście oraz gatunek), oczyszczenie tekstu, tokenizację, stemming, wykonanie analizy częstości słów i analizy sentymentu przy użyciu słowników AFINN i Bing oraz klastrowanie tekstów piosenek z wykorzystaniem reprezentacji Bag of Words oraz TF-IDF. Dodatkowo system generuje wizualizacje wyników: chmury słów, wykresy sentymentu w podziale na lata, wykresy metody łokcia oraz wizualizacje klastrów z wykorzystaniem PCA.

2. Cele systemu:

- Wczytanie tekstów wejściowych piosenek (plik .txt) z odpowiednim kodowaniem (UTF-8)
- Odczytanie podstawowych metadanych utworów (tytuł, wykonawca, rok, miejsce na liście Billboard oraz gatunek muzyczny)
- Przetwarzanie i oczyszczanie tekstu piosenek (tokenizacja, stemming, usuwanie stopwords)
- Zliczenie częstości występowania słów oraz ich wizualizacja w formie chmury
- Wizualizacja najczęściej występujących słów dla całego zbioru piosenek oraz osobno dla poszczególnych lat
- Przeprowadzenie analizy sentymentu tekstów piosenek z użyciem słowników w plikach CSV:
 - AFINN
 - Bing
- Wizualizacja wyników sentymentu za pomocą wykresów słupkowych i czasowych
- Zestawienie wyników sentymentu między analizowanymi latami
- Przeprowadzenie klastrowania tekstów metodą k-średnich z wykorzystaniem reprezentacji:
 - Bag of Words
 - TF-IDF
- Dobór liczby klastrów za pomocą metody łokcia
- Wizualizacja wyników klastrowania (PCA)
- Wygenerowanie raportu HTML zgodnego z podejściem Reproducible Research

3. Wymagania funkcjonalne:

- **Wczytywanie danych:**
 - Skrypt powinien umożliwić wczytanie danych tekstowych z lokalnych plików .txt
 - Skrypt powinien obsługiwać kodowanie UTF-8
 - Skrypt powinien umożliwiać wczytanie wielu plików tekstowych znajdujących się w folderze data
 - Skrypt powinien umożliwiać odczytanie podstawowych metadanych utworów: tytułu, wykonawcy, roku, miejsca na liście oraz gatunku muzycznego
 - Skrypt powinien umożliwiać oddzielenie metadanych od tekstu piosenki
- **Przetwarzanie i oczyszczanie danych**
 - Skrypt powinien umożliwiać podział tekstu na pojedyncze słowa (tokenizacja)
 - Skrypt powinien umożliwiać usunięcie pustych elementów oraz zbędnych znaków specjalnych
 - Skrypt powinien umożliwiać usunięcie tekstów niespełniających warunków analizy
 - Skrypt powinien umożliwiać usunięcie stopwords w języku angielskim
 - Skrypt powinien umożliwiać usunięcie dodatkowych wyrażeń charakterystycznych dla tekstów piosenek i niewnoszących istoty do analizy, np. "oh", "yeah", "hey"
 - Skrypt powinien umożliwić wykonanie stemmingu
- **Analiza częstości:**
 - Skrypt powinien umożliwiać zliczenie liczby wystąpień słów w całym zbiorze piosenek
 - Skrypt powinien umożliwiać posortowanie słów według częstości
 - Skrypt powinien umożliwiać przedstawienie wyników w tabeli
 - Skrypt powinien generować chmurę słów dla całego zbioru piosenek
 - Skrypt powinien generować osobne chmury słów dla poszczególnych lat
- **Analiza sentymentu (Słowniki w plikach CSV)**
 - Skrypt powinien umożliwiać wczytanie słowników: afinn.csv, bing.csv
 - Skrypt powinien umożliwiać dopasowanie słów z tekstów piosenek do słowników sentymentu
 - Skrypt powinien umożliwiać zliczenie średniego sentymentu rocznie (słownik AFINN)
 - Skrypt powinien umożliwiać zliczenie słów pozytywnych i negatywnych (słownik Bing)
- **Klastrowanie tekstów**
 - Skrypt powinien umożliwiać utworzenie reprezentacji tekstów piosenek w postaci Bag of Words
 - Skrypt powinien umożliwiać utworzenie reprezentacji tekstów z wykorzystaniem TF-IDF
 - Skrypt powinien umożliwiać przeprowadzenie klastrowania tekstów metodą k-średnich
 - Skrypt powinien umożliwiać dobór liczby klastrów za pomocą metody łokcia

- Skrypt powinien umożliwiać wizualne zestawienie wyników klastrowania
- **Wizualizacja danych:**
 - Skrypt powinien umożliwiać wizualizację wyników (wykresy ggplot2)
 - Skrypt powinien generować wykres średniego sentymentu rocznie (słownik AFINN)
 - Skrypt powinien generować wykres liczby słów pozytywnych i negatywnych rocznie (słownik Bing)
 - Skrypt powinien generować wykres indeksu sentymentu rocznie
 - Skrypt powinien generować wykresy wspierające wybór optymalnej liczby klastrów dla reprezentacji Bag of Words oraz TF-IDF
 - Skrypt powinien generować wykresy przedstawiające wyniki klastrowania z wykorzystaniem analizy głównych składowych (PCA)
- **Agregacja danych:**
 - Skrypt powinien agregować sentyment w podziale na lata
 - Skrypt powinien łączyć wyniki analizy sentymentu z różnych słowników w jednej ramce danych
 - Skrypt powinien usuwać brakujące wartości (NA)
 - Skrypt powinien generować końcowe podsumowanie analizy, obejmujące liczbę przeanalizowanych piosenek, analizowane lata, liczbę unikalnych słów, liczbę rdzeni słów oraz optymalną liczbę klastrów
- **Generowanie raportu:**
 - Skrypt powinien umożliwiać wygenerowanie raportu HTML
 - Raport powinien zawierać kod, wyniki analizy, wykresy i podsumowanie
 - Raport powinien umożliwiać odtworzenie analizy zgodnie z podejściem Reproducible Research

4. Wymagania нефункционалне:

- **Wydajność:**
 - Analiza zestawu danych obejmujących 60 tekstów piosenek powinna trwać nie dłużej niż kilka minut
- **Bezpieczeństwo:**
 - System powinien zapewnić poprawność danych wyjściowych
 - Skrypt nie powinien modyfikować oryginalnych plików .txt z tekstami piosenek
- **Niezawodność:**
 - Skrypt powinien poprawnie obsługiwać wiele plików tekstowych .txt znajdujących się w folderze data
 - Skrypt powinien poprawnie obsługiwać brakujące wartości
 - Skrypt powinien pomijać rekordy, w których brakuje roku lub tekstu piosenki
- **Użyteczność:**
 - Wykresy powinny być czytelne i zawierać odpowiednie etykiety

- Skrypt powinien umożliwiać wykonanie wizualizacji wyników z użyciem biblioteki ggplot2 oraz motywu theme_minimal() dla lepszej czytelności
- Skrypt powinien umożliwiać generowanie chmury słów z wykorzystaniem kolorystyki RColorBrewer
- Raport HTML powinien prezentować wyniki analizy w uporządkowany sposób, umożliwiając łatwe prześledzenie kolejnych etapów: wczytania danych, czyszczenia tekstu, analizy częstości, analizy sentymentu oraz klastrowania
- **Kompatybilność:**
 - Skrypt powinien być kompatybilny z językiem R w wersji 4.0 lub nowszej
 - Skrypt powinien korzystać z bibliotek tm, tidyverse, tidytext, textdata, ggplot2, wordcloud, RColorBrewer, SnowballC, cluster

5. Interfejsy użytkownika:

- **Wejście:**
 - Pliki tekstowe .txt zawierające teksty piosenek (powinny zawierać podstawowe metadane utworu, takie jak: tytuł, wykonawca, rok, miejsce na liście Billboard oraz gatunek muzyczny)
 - Pliki słowników w formacie .csv. (afinn.csv, bing.csv)
- **Wyjście:**
 - Tabela z częstością występowania słów
 - Chmura słów (wordcloud) dla całego zbioru piosenek oraz dla poszczególnych analizowanych lat
 - Wykresy sentymentu w podziale na lata według słowników (AFINN, Bing).
 - Wykresy wspierające analizę klastrowania tekstów (elbow method, PCA) dla reprezentacji Bag of Words oraz TF-IDF
 - Raport końcowy w formacie HTML

6. Wymagania dotyczące danych:

- Skrypt zakłada, że dane tekstowe są w języku angielskim
- Skrypt nie obsługuje analizy sentymentu dla innych języków
- Skrypt wykorzystuje teksty piosenek zapisane w lokalnych plikach .txt
- Każdy plik .txt powinien zawierać tekst jednej piosenki oraz podstawowe metadane: tytuł, wykonawcę, rok, miejsce na liście Billboard oraz gatunek muzyczny
- Skrypt zakłada, że analizowane dane dotyczą piosenek z zestawienia Billboard Year-End Hot 100 singles dla lat: 2000, 2005, 2010, 2015, 2020 oraz 2025
- Skrypt wykorzystuje słowniki sentymentu dostępne w plikach .csv (AFINN, Bing)
- Skrypt nie obsługuje analizy danych tekstowych z innych źródeł niż lokalne pliki .txt
- Skrypt zakłada, że pliki wejściowe są zapisane z kodowaniem UTF-8

Słownictwo dokumentacji:

- **Token:** pojedynczy element tekstu (słowo)
- **Stopwords:** słowa niewnoszące wartości semantycznej do analizy
- **Sentiment:** emocjonalne nastawienie w tekście
- **Słownik sentymentów:** lista słów i ich ocen wg sentymentu

- **Stem**: forma słowa po sprowadzeniu go do rdzenia
- **Stemming**: proces sprowadzania słów do ich rdzeni
- **AFINN**: słownik sentymentu przypisujący słowom wartości liczbowe określające ich nacechowanie emocjonalne
- **Bing**: słownik sentymentu klasyfikujący słowa jako pozytywne lub negatywne
- **Chmura słów**: wizualizacja częstości występowania słów, w której większy rozmiar słowa oznacza jego częstsze występowanie
- **Bag of Words**: reprezentacja tekstu oparta na liczbie wystąpień słów, bez uwzględniania ich kolejności
- **TF-IDF**: metoda ważenia słów, która zwiększa znaczenie słów charakterystycznych dla danego dokumentu i zmniejsza znaczenie słów często występujących w całym zbiorze
- **Klastrowanie**: metoda grupowania obiektów podobnych do siebie na podstawie wybranych cech
- **PCA**: analiza głównych składowych, wykorzystywana do przedstawienia danych wielowymiarowych na wykresie dwuwymiarowym
- **Reproducible Research**: podejście, w którym kod, dane i wyniki są przygotowane w sposób umożliwiający powtórzenie analizy
- **Raport HTML**: plik wynikowy zawierający kod, wyniki analizy, wykresy oraz podsumowanie

Przypadki użycia (use cases)

- **Użytkownik:**

- wczytuje pliki .txt z tekstami piosenek
- uruchamia analizę
- wyświetla wyniki
- analizuje chmury słów, wykresy sentymentu i wyniki klastrowania
- generuje wykresy i raport HTML

- **Skrypt/system:**

- wczytuje teksty piosenek i ich metadane
- przetwarza tekst
- oczyszcza tekst
- wykonuje tokenizację i stemming
- analizuje częstość występowania słów
- generuje chmury słów dla całego zbioru i poszczególnych lat
- analizuje sentyment tekstu przy użyciu słowników AFINN i Bing
- generuje wykres sentymentu z podziałem na lata
- przeprowadzana klastrowanie tekstów
- generuje wykresy wspierające wybór liczby klastrów oraz wizualizacje wyników klastrowania
- generuje raport końcowy w formacie HTML

- **Testowe przypadki użycia:**

- Test z plikami .txt zawierającymi poprawne teksty piosenek i komplet metadanych
- Test z plikiem .txt zawierającym tekst o pozytywnym sentymencie
- Test z plikiem .txt zawierającym tekst o negatywnym sentymencie
- Test z plikiem .txt zawierającym tekst o mieszanym sentymencie
- Test z plikiem .txt zawierającym brakujące wartości
- Test z plikiem .txt zawierającym znaki specjalne, interpunkcję oraz powtórzenia charakterystyczne dla tekstów piosenek

Scenariusze użytkownika (user stories)

Scenariusz 1: Wsparcie producenta muzycznego w analizie cech popularnych piosenek

- **Jako:** Producent muzyczny
- **Chcę:** Przeanalizować teksty najpopularniejszych piosenek z list Billboard
- **Aby:** Zidentyfikować najczęściej występujące słowa, sentyment oraz podobieństwa między utworami, które osiągnęły wysokie miejsca na listach przebojów, a otrzymane wyniki wykorzystać przy tworzeniu nowych utworów

Kryteria akceptacji:

- Użytkownik może wczytać pliki tekstowe .txt z tekstami popularnych piosenek
- Skrypt analizuje częstość występowania słów i generuje chmury słów
- Skrypt przeprowadza analizę sentymentu przy użyciu słowników AFINN i Bing
- Skrypt grupuje piosenki według podobieństwa tekstów z wykorzystaniem Bag of Words i TF-IDF
- Użytkownik może wykorzystać wyniki jako wsparcie przy analizie cech tekstów popularnych utworów

Scenariusz 2: Analiza sentymentu hitów muzycznych

- **Jako:** Analityk danych w sektorze muzycznym
- **Chcę:** Porównać sentyment tekstów piosenek z różnych lat
- **Aby:** Sprawdzić, czy popularne utwory były bardziej pozytywne czy negatywne w wybranych okresach

Kryteria akceptacji:

- Użytkownik może wczytać pliki .txt zawierające teksty piosenek z wybranych lat
- Skrypt poprawnie przetwarza i oczyszcza teksty piosenek przed analizą sentymentu
- Skrypt przeprowadza analizę sentymentu z wykorzystaniem słowników AFINN i Bing
- Skrypt zlicza liczbę słów pozytywnych i negatywnych w podziale na lata
- Skrypt oblicza średni sentyment rocznie
- Skrypt generuje wykresy umożliwiające porównanie sentymentu tekstów piosenek między analizowanymi latami
- Użytkownik może na podstawie wyników określić, w których latach teksty piosenek miały bardziej pozytywne lub negatywne nacechowanie emocjonalne

Scenariusz 3: Klastrowanie tekstów piosenek

- **Jako:** Badacz kultury popularnej
- **Chcę:** Pogrupować teksty piosenek według podobieństwa używanego słownictwa
- **Aby:** Sprawdzić, czy utwory tworzą podobne grupy językowe lub słownikowe

Kryteria akceptacji:

- Użytkownik może uruchomić analizę klastrowania tekstów piosenek
- Skrypt przygotowuje reprezentację tekstów z wykorzystaniem Bag of Words oraz TF-IDF
- Skrypt przeprowadza klastrowanie metodą k-średnich
- Skrypt generuje wykresy wspierające wybór liczby klastrów
- Skrypt przedstawia wyniki klastrowania z wykorzystaniem wizualizacji PCA